

# QML (Angle Embedding) y DNN para b-Tagging en Jets de bajo momento

Juan

Instituto de Física



12 de agosto de 2025

# Agenda

- 1 Introducción
- 2 Quantum Machine Learning
- 3 Circuito QML
- 4 Metodología
- 5 Resultados
- 6 Conclusiones
- 7 Referencias




# Contexto y Objetivo

- Que son los jets?






# Contexto y Objetivo

- Jets de bajo momento (LowPt) en colisiones pp.



- Motivante






# ¿Qué es QML?

- Híbrido cuántico-clásico
- Se aprovecha superposición y entrelazamiento.
- Embedding de datos clásicos en qubits.


# Angle Embedding

- Para un vector  $\mathbf{x} = [x_1, \dots, x_n]$  normalizado en  $[-\pi, \pi]$ .
- Aplica rotaciones  $RX(x_i)$  o  $RY(x_i)$  en cada qubit.
- $n$  características  $\rightarrow n$  qubits.






# Angle Embedding



# Detalles del Circuito

- Dispositivo: `lightning.gpu`
- Embedding: `qml.AngleEmbedding(inputs, wires=0..15)`
- Capas: `qml.StronglyEntanglingLayers(weights, wires=0..15)`
- Salida:  $\langle Z_0 \rangle \in [-1, 1]$



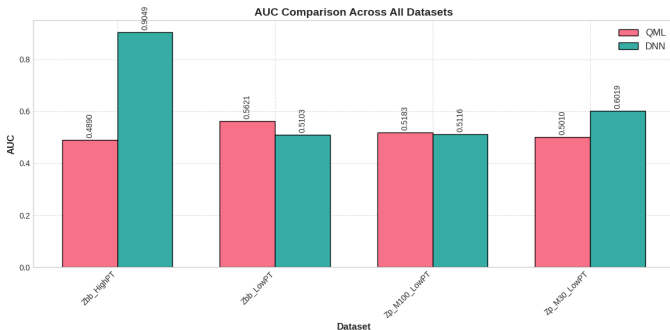
**Cada capa contiene:**

- ➊ **Rotaciones locales:**  $RX(\theta)$ ,  $RY(\phi)$ ,  $RZ(\lambda)$ 
  - ▶ Parámetros entrenables
  - ▶ Orientan cada qubit individualmente
- ➋ **Puertas entrelazantes:** CNOT, CZ
  - ▶ Conectan qubits  $\rightarrow$  correlaciones no-clásicas
  - ▶ Estado global  $\neq$  suma de estados individuales


- 1 Carga y preprocesamiento de histogramas ROOT
- 2 Normalización ( $\arctan$ )
- 3 **QML**: 16 qubits, AngleEmbedding, 4 capas de StronglyEntanglingLayers, medida PauliZ
- 4 **DNN**: arquitectura 16-64-32-1 con ReLU/tanh
- 5 Entrenamiento (Adam, 10 epochs, batch=64)
- 6 Evaluación: AUC y Tagging Power


# Métricas Comparativas

- AUC y Tagging Power para cada dataset:
  - ▶ Zbb\_LowPT, Zbb\_HighPT, Zp\_M30\_LowPT, Zp\_M100\_LowPT
- Gráficas de:
  - ▶ Distribución de predicciones
  - ▶ Evolución de pérdida y accuracy



AUC Comparison: Low PT vs High PT





# Principales Conclusiones: Rendimiento

- DNN vs QML: DNN mejor AUC (0.63 vs 0.52) y tagging en HighPT ( $\epsilon \approx 0.12$ ); QML casi no etiqueta.
- HighPT < LowPT: DNN AUC 0.9 vs AUC 0.5; LowPt difícil de separar.
- $Z \text{ normal} < Z'$ : las muestras con masas teóricas distorsionan la distribución y reducen la discriminación.



# Principales Conclusiones: Limitaciones y Siguietes Pasos

- Muestra pequeña (1000 eventos)
- Explorar configuraciones distintas del cicuito.
- Explorar otras características relevantes del jet.



A. Gianelle et al., "First implementation of Quantum Machine Learning for b-jet tagging at LHCb", 2021. [Link](#)



A. Gianelle et al., "Quantum Machine Learning for b-jet charge identification", 2022. [Link](#)



Youtube chanel 'Blochh Sphere', "Quantum Neural Networks explained", 2024.

Video