

QML (Angle Embedding) y DNN para b-Tagging en Jets de bajo momento

Juan

Instituto de Física



12 de agosto de 2025

Agenda

- 1 Introducción
- 2 Introducción
- 3 Quantum Machine Learning
- 4 Circuito QML
- 5 Metodología
- 6 Resultados
- 7 Conclusiones




Contexto y Objetivo

- Que son los jets?






Contexto y Objetivo

- Jets de bajo momento (LowPt) en colisiones pp.



- Motivante






¿Qué es QML?


- Híbrido cuántico-clásico
- Se aprovecha superposición y entrelazamiento.
- Embedding de datos clásicos en qubits.

Angle Embedding

- Para un vector $\mathbf{x} = [x_1, \dots, x_n]$ normalizado en $[-\pi, \pi]$.
- Aplica rotaciones $RX(x_i)$ o $RY(x_i)$ en cada qubit.
- n características $\rightarrow n$ qubits.




Angle Embedding



Detalles del Circuito

- Dispositivo: `lightning.gpu`
- Embedding: `qml.AngleEmbedding(inputs, wires=0..15)`
- Capas: `qml.StronglyEntanglingLayers(weights, wires=0..15)`
- Salida: $\langle Z_0 \rangle \in [-1, 1]$



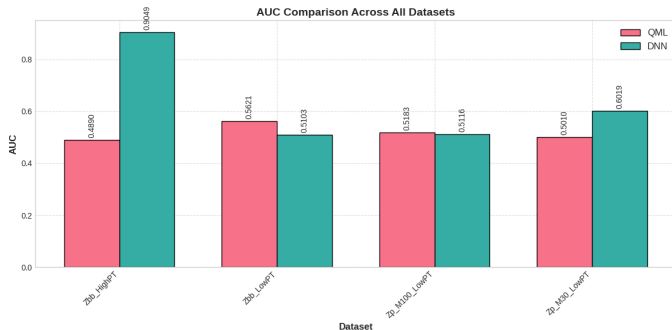
Cada capa contiene:

- ➊ **Rotaciones locales:** $RX(\theta)$, $RY(\phi)$, $RZ(\lambda)$
 - ▶ Parámetros entrenables
 - ▶ Orientan cada qubit individualmente
- ➋ **Puertas entrelazantes:** CNOT, CZ
 - ▶ Conectan qubits \rightarrow correlaciones no-clásicas
 - ▶ Estado global \neq suma de estados individuales


- 1 Carga y preprocesamiento de histogramas ROOT
- 2 Normalización (\arctan)
- 3 **QML**: 16 qubits, AngleEmbedding, 4 capas de StronglyEntanglingLayers, medida PauliZ
- 4 **DNN**: arquitectura 16-64-32-1 con ReLU/tanh
- 5 Entrenamiento (Adam, 10 epochs, batch=64)
- 6 Evaluación: AUC y Tagging Power


Métricas Comparativas

- AUC y Tagging Power para cada dataset:
 - ▶ Zbb_LowPT, Zbb_HighPT, Zp_M30_LowPT, Zp_M100_LowPT
- Gráficas de:
 - ▶ Distribución de predicciones
 - ▶ Evolución de pérdida y accuracy



AUC Comparison: Low PT vs High PT





Principales Conclusiones: Rendimiento

- DNN vs QML: DNN mejor AUC (0.63 vs 0.52) y tagging en HighPT ($\epsilon \approx 0.12$); QML casi no etiqueta.
- HighPT < LowPT: DNN AUC 0.9 vs AUC 0.5; LowPt difícil de separar.
- $Z \text{ normal} < Z'$: las muestras con masas teóricas distorsionan la distribución y reducen la discriminación.

Principales Conclusiones: Limitaciones y Siguietes Pasos

- Muestra pequeña (1000 eventos)
- Explorar configuraciones distintas del cicuito.
- Explorar otras características relevantes del jet.